

Analyse en composantes principales

Réalisé Par: Aroubite - Hrouch - Ghoundal - Rakib

Encadré par: M. Ghazdali

Sommaire

Présentation concernant la théorie générale de l'ACP

01

Objectif de l'ACP

02

Les étapes de l'ACP

03

Application simple

Objectif

L'analyse en composantes principales est une méthode de la famille de l'analyse des données et plus généralement de la statistique multivariée, dont l'objectif est de résumer un ensemble de données.

Objectif


L'idée centrale de l'analyse en composantes principales (ACP) est de réduire la dimensionnalité d'un ensemble de données composé d'un grand nombre de variables interdépendantes tout en conservant autant que possible la variation présente dans l'ensemble de données.

Objectif

Ceci est réalisé en transformant en un nouvel ensemble de variables, les composantes principales (PC), qui ne sont pas corrélées et qui sont ordonnées de sorte que les premières conservent la majeure partie de la variation présente dans toutes les variables d'origine.

Les étapes

Pour déterminer les
composantes
principales



Les étapes de l'ACP

01

**Tableau des
données**

02

**Centrer les
données**

03

**Matrice
de covariance**

04

Diagonalisation

Trouver les
valeurs/vecteurs
propres.

05

**Définir les
composantes
principales**

Choisir
la dimension à retenir et
déterminer les axes
principaux

Tableau des données

On considère les données suivantes:

Student	Math	English	Art
1	90	60	90
2	90	90	30
3	60	60	60
4	60	60	90
5	30	30	30

Tableau des données

La matrice correspondante est:

$$\mathbf{A} = \begin{bmatrix} 90 & 60 & 90 \\ 90 & 90 & 30 \\ 60 & 60 & 60 \\ 60 & 60 & 90 \\ 30 & 30 & 30 \end{bmatrix}$$

02

Calcul de la moyenne

$$\bar{A} = [66 \quad 60 \quad 60]$$

Matrice de covariance

Rappel:

La formule pour calculer la covariance:

$$\text{cov}(X,Y) = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{x})(Y_i - \bar{y})$$

C'est quoi la matrice de covariance?

La matrice de covariance est une matrice symétrique $p \times p$ (où p est le nombre de dimensions) qui a comme entrées les covariances associées à toutes les paires possibles des variables initiales. Par exemple, pour un ensemble de données tridimensionnel avec 3 variables x , y et z , la matrice de covariance est une matrice 3×3 de ceci à partir de :

$$\begin{bmatrix} Cov(x, x) & Cov(x, y) & Cov(x, z) \\ Cov(y, x) & Cov(y, y) & Cov(y, z) \\ Cov(z, x) & Cov(z, y) & Cov(z, z) \end{bmatrix}$$

Rappels:

$$\text{Cov}(a,a)=\text{Var}(a)$$

$$\text{Cov}(a,b)=\text{Cov}(b,a)$$

$$\begin{bmatrix} \text{Cov}(x,x) & \text{Cov}(x,y) & \text{Cov}(x,z) \\ \text{Cov}(y,x) & \text{Cov}(y,y) & \text{Cov}(y,z) \\ \text{Cov}(z,x) & \text{Cov}(z,y) & \text{Cov}(z,z) \end{bmatrix}$$



$$\begin{bmatrix} \text{var}(x) & \text{cov}(x,y) & \text{cov}(x,z) \\ \text{cov}(x,y) & \text{var}(y) & \text{cov}(y,z) \\ \text{cov}(x,z) & \text{cov}(y,z) & \text{var}(z) \end{bmatrix}$$

Matrice de covariance

Pourquoi la matrice de covariance est utile?

C'est en fait le signe de la covariance qui compte :


- si positif alors : les deux variables augmentent ou diminuent ensemble (corrélé)
- si négatif alors : L'un augmente quand l'autre diminue (Inversement corrélé)

03

Matrice de covariance

Calcul de la matrice de covariance:

	<i>Math</i>	<i>English</i>	<i>Arts</i>
1	90	60	90
2	90	90	30
3	60	60	60
4	60	60	90
5	30	30	30



	<i>Math</i>	<i>English</i>	<i>Art</i>
<i>Math</i>	504	360	180
<i>English</i>	360	360	0
<i>Art</i>	180	0	720

Diagonalisation

Le but est de résoudre l'équation:

$$\det(A - \lambda I) = 0$$

$$\det \left(\begin{pmatrix} 504 & 360 & 180 \\ 360 & 360 & 0 \\ 180 & 0 & 720 \end{pmatrix} - \lambda \begin{pmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix} \right)$$

$$\det \begin{pmatrix} 504 - \lambda & 360 & 180 \\ 360 & 360 - \lambda & 0 \\ 180 & 0 & 720 - \lambda \end{pmatrix}$$

04

Diagonalisation

$$-\lambda^3 + 1584\lambda^2 - 641520\lambda + 25660800 = 0$$

$$\lambda \approx 44.81966..., \lambda \approx 629.11039..., \lambda \approx 910.06995...$$

05

Diagonalisation

Maintenant on calcule les vecteurs propres, suivant la formules suivantes:

$$AV = \lambda V$$

The diagram illustrates the eigenvalue equation $AV = \lambda V$. It features three labels with arrows pointing to the corresponding parts of the equation: 'Matrix' points to A , 'Eigenvalue' points to λ , and 'Eigenvector' points to V . The labels are written in a stylized, italicized font matching the color of the variables they point to.

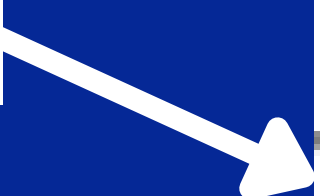
05

Diagonalisation

$$\begin{pmatrix} -3.75100... \\ 4.28441... \\ 1 \end{pmatrix}, \begin{pmatrix} -0.50494... \\ -0.67548... \\ 1 \end{pmatrix}, \begin{pmatrix} 1.05594... \\ 0.69108... \\ 1 \end{pmatrix}$$

On fait un tri décroissant des valeurs propres:

$$\lambda \approx 44.81966..., \lambda \approx 629.11039..., \lambda \approx 910.06995...$$


$$\begin{pmatrix} 910.06995 \\ 629.11039 \\ 44.81966 \end{pmatrix}$$

in

Définir les composantes principales

$$\mathbf{W} = \begin{bmatrix} 1.05594 & -0.50494 \\ 0.69108 & -0.67548 \\ 1 & 1 \end{bmatrix}$$